迷失因子道：解耦资产价格趋势
——基于图像识别的另一种思路

姓名：何跃成　学号：24300680058

课程：ECON30122h.01 公司金融 [H]

2025 年 12 月 9 日

1　引言

资产定价的研究正面临“因子动物园”带来的多重挑战：传统的线性模型难以捕捉复杂的非线性市场动态，而常规的机器学习方法虽然提升了预测精度，却依然无法摆脱对人工预设因子（如动量、反转等数值指标）的路径依赖。因子同质化、密集化使得构造出的特征空间趋于雷同，限制了模型的泛化能力和创新空间。因此，本文核心想要探讨的问题是：能否通过一种“解耦”（Decoupling）的机制，切断资产价格预测对人工数值因子的强依赖，直接从市场最原始的量价形态中提取驱动价格演变的内在规律?

基于此，本文着重回顾一种基于计算机视觉的资产定价新范式。借鉴计算机系统中降低模块依赖性的“解耦”思想，我们尝试回归价格趋势的本源，将时间序列重构为可视化的 K 线图像，并利用卷积神经网络（CNN）强大的表征学习能力，自动挖掘那些被传统数值模型遗漏的复杂视觉模式。这一研究不仅在理论上验证了视觉形态中蕴含的市场非有效性信息，还在现实层面用这种“看图说话”的端到端预测模式，产生与传统因子低相关性的“视觉 Alpha”，为量化投资策略提供了全新的思路与增量价值。

2　文献综述

本文将从传统因子模型的构建机理出发，梳理机器学习在结构化因子整合中的突破，并进一步探讨以文本和关系网络为代表的非结构化数据在资产定价中的前沿应用。图 1 展示了机器学习在资产定价中的应用演进路线。

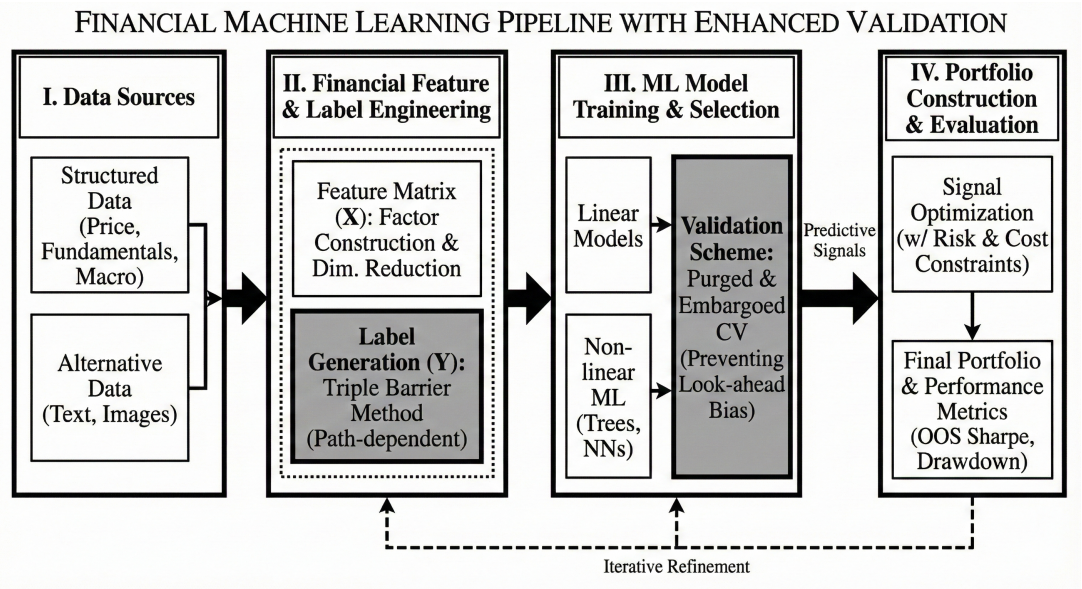


图 1　机器学习用于资产定价演进路线图

2.1　传统资产定价模型：线性范式与因子构建机理

传统资产定价理论的核心在于通过线性模型量化风险与收益的权衡关系。Sharpe (1964) 提出的资本资产定价模型（CAPM）奠定了这一领域的基石，确立了预期超额收益仅由单一市场风险因子驱动的线性范式：

$$E[R_i] - R_f = \beta_i(E[R_m] - R_f) \tag{1}$$

其中，β_i 衡量资产对市场系统性风险的暴露程度。为了捕捉市场风险以外的异象，Fama 和 French (1993) 引入了市值（SMB）和账面市值比（HML）因子，将其扩展为多因子模型：

$$E[R_{it}] - R_{ft} = \beta_i MKT_t + s_i SMB_t + h_i HML_t + \alpha_{it} \tag{2}$$

这一阶段的多因子构建强调“人工挖掘”（Handcrafted Features），研究者基于经济理论以及对市场的直觉判断，设计出一系列预测因子对非常规收益进行解释，比如著名的“规模效应”、“动量效应”等 [1]。

然而，正如前文所叙，这种同质化的构造模式暴露了诸多局限性。本文还想强调，正如公式 (2) 所示，传统线性模型假设因子与收益之间存在线性关系，忽略了因子间可能存在的复杂交互效应。例如，规模大小与动量效应可能在不同市场环境下产生不同的影响，这种非线性关系难以通过简单的线性叠加来捕捉。因此，如何突破线性范式的束缚，成为下一阶段资产定价领域亟待解决的问题。

2.2 机器学习驱动下的因子整合

针对传统模型的痛点，以 Gu et al. (2020) 为代表的研究标志着资产定价进入了“机器学习时代”。该研究对包括线性回归、广义线性模型、随机森林、梯度提升树（GBRT）和神经网络在内的多种机器学习算法进行了大规模实证比较 [1]。

其核心贡献在于揭示了机器学习在资产定价中的优越性并非仅仅源于数据量的增加，而是源于模型对**非线性交互（Non-linear Interactions）**的捕捉能力。实证数据显示，允许预测因子之间进行复杂交互的模型（如神经网络和树模型），其样本外预测的 R^2 显著高于传统线性模型。尤其值得注意的是，Gu et al. (2020) 还从“控制变量”的角度，系统评估了不同因子组合对预测性能的贡献，并以此为基础指导资产配置。由于这一部分在课上详细汇报过，本人给出自己所绘制的图 2，以补充说明机器学习在资产定价中的应用路径。

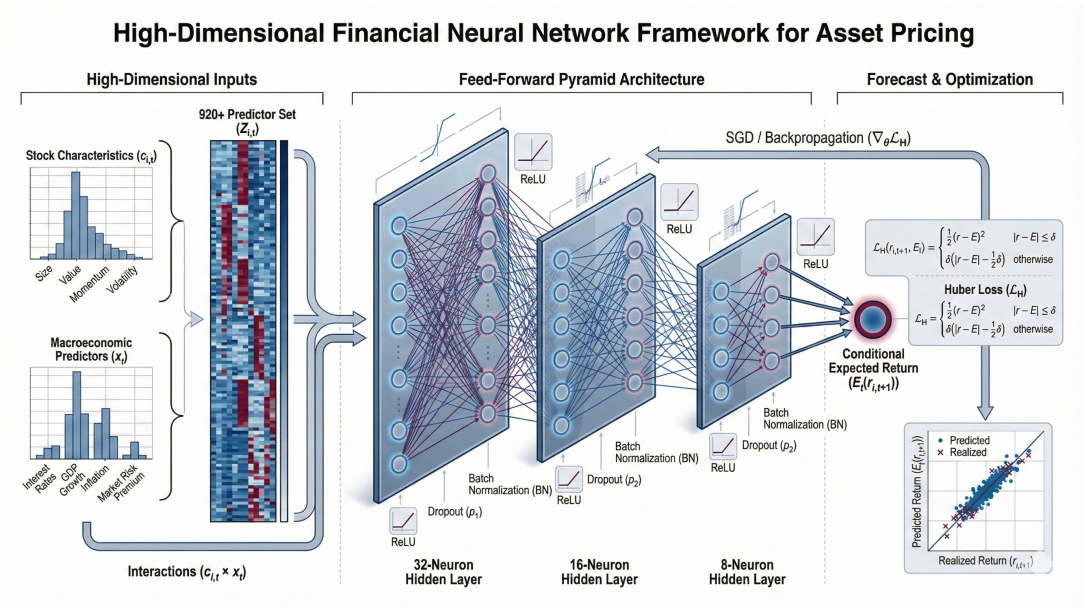


图 2 机器学习预测资产定价路线图

2.3 非结构化信息的异军突起：以新闻文本和图神经网络为例

尽管如此，人们依然迷失在因子的世界里，无非是这个世界由于神经网络的发展，在维度上互相交织、延拓，仍然逃不出“人为”的手掌。

但随着深度学习技术的发展，资产定价的信息集从传统的结构化数据（量价、财报）迅速扩展至非结构化数据。其中，自然语言处理（NLP）和图神经网络（GNN）的应用最为典型。这两种方法从因子-文本-关系图谱的多模态角度，挖掘了传统数值因子难以覆盖的信息增量。

1. 大语言模型与文本情绪挖掘

文本数据是金融市场中信息含量极高的一种非结构化模态。早期的文本分析主要依赖词袋模型（Bag-of-Words），而 Lopez-Lira and Tang (2023) 的最新研究展示了大语言模型（LLM）的颠覆性能力 [3]。他们利用 ChatGPT（GPT-4）直接解读财经新闻标题，发现 LLM 具备类似人类专家的推理能力，能够准确判断新闻对股价的潜在影响。

2. 图神经网络与资产关联挖掘

除了孤立的个体信息，资产之间的相互关联也是定价的重要来源。传统模型往往假设资产回报是独立同分布的（I.I.D.），忽略了产业链、行业竞争等网络效应。Feng et al. (2019) 开创性地提出了“关系型股票排序”（RSR）模型，利用图卷积网络（GCN）将行业分类和供应链关系编码进预测模型 [4]。在此基础上，Xu et al. (2025) 进一步提出了 LED-GNN 模型，利用大语言模型从新闻中动态提取股票间的隐性关系，构建动态图结构 [5]。

综上所述，深度学习技术为我们整合语言和关系网络等非结构化信息提供了强大工具，本文接下来将详细探讨基于“K 线图”的非结构化信息提取模式，并以 Jiang et al. (2023) 的研究为核心，以中国市场的数据复刻为例，验证其有效性。

3 研究展望：解耦与重构——图像识别的金融学透视

3.1 解耦的本质：从“有损压缩”到“全息映射”

传统的技术分析为人诟病，其一是因为难以用数学语言简单勾勒出“看到 K 线图”到“做出预测”的过程，其二是因为在有效市场假说下，过去的历史信息被认为完全包含在当前信息里。

然而，计算机视觉的兴起为我们提供了新的抓手——将离散的数据点复原为图像信号，并叠加卷积层和池化层模拟人眼感知图像的方式。这是一种从“有损压缩”的数据点复原回“全息映射”的 OHLC 图像的过程。正如图 3 所示，我们参考 Jiang et al. (2023) 的研究通过将时间序列数据转换为图像信号，建立了从原始数据到视觉信号的端到端流程。

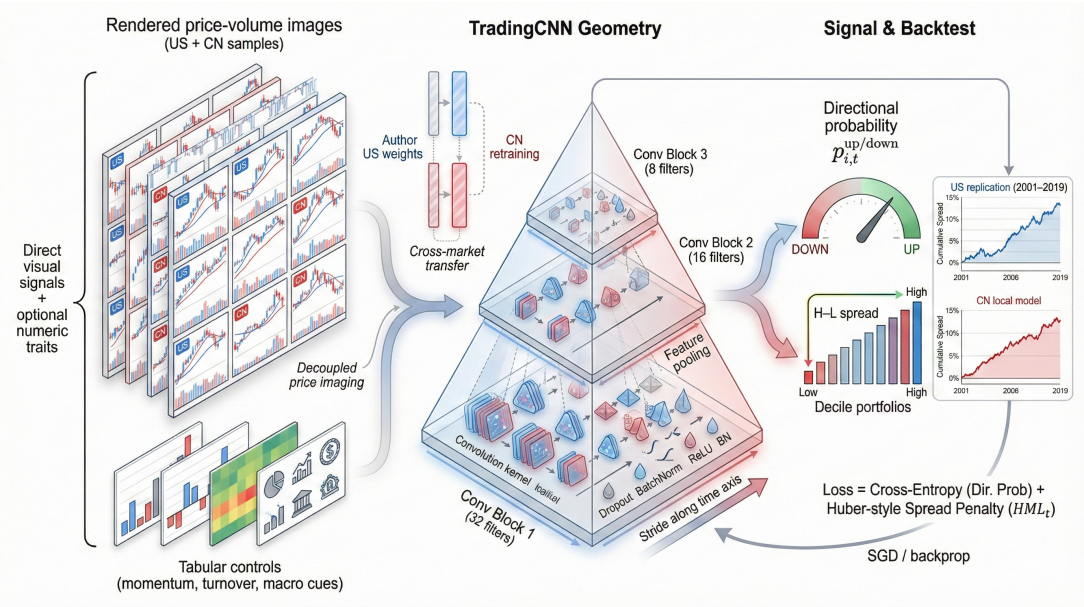


图 3　从原始数据到视觉信号的端到端流程

如图 4 所示，在中国市场的样本中，我们以 20 日为上下窗口、将价格数据缩放后形成 K 线、并将成交量作为底部柱形，形成了完整的图像样本。

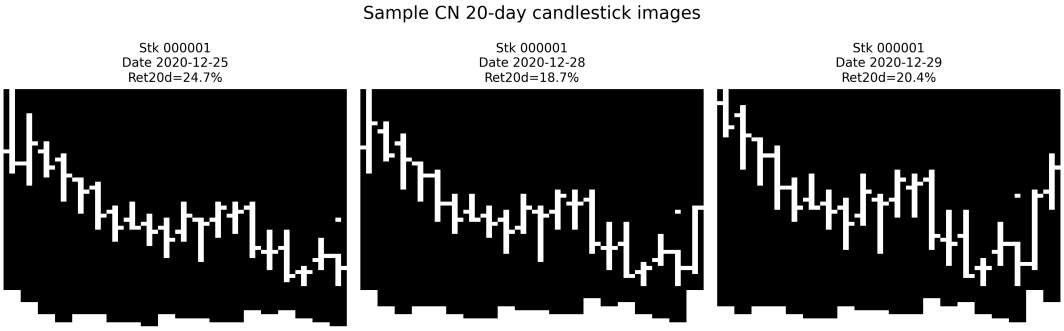


图 4　中国 A 股 20 日窗价格—成交量图像样本

3.2　打开黑箱：卷积层级与金融语义的映射

受篇幅限制，笔者难以在此处将卷积的“哲学”进行详细展开，只能就最宏观的卷积层，拆解 TradingCNN 的网络结构，尝试建立起卷积操作与金融学意义的映射关系。

实际上，Jiang et al. (2023) 所采用的多层卷积网络 [2]，模拟了人类交易员“由点及面”的认知过程。正如计算机视觉经典研究所示，CNN 具备从低级纹理到高级语义的层级化特征提取能力（Zeiler and Fergus, 2014）[6]：

- **浅层卷积（微观结构层）：**网络的最初几层主要识别图像中的“边缘”和“纹理”。在金融语境下，这对应着识别单日的 K 线形态（如长上影线、十字星）以及微观

的波动率特征。

- **中层卷积（局部趋势层）：**引入 Yu and Koltun (2015) 提出的膨胀卷积（Dilated Convolution）后 [7]，随着感受野的扩大，网络开始识别线条的组合。这一层级能够捕捉均线的排列方式（如多头排列）、价格与均线的交叉以及成交量的局部放大。这对应着技术分析中的短期趋势确认。
- **深层卷积（形态语义层）：**在网络的末端，高度抽象的特征被提取出来。此时，模型不再关注单个像素，而是识别整体的几何形态，如“头肩顶”、“双底”或“三角形收敛”。

这种层级化的特征提取，使得 CNN 能够观测到传统数值因子（如单纯的 R_{t-1}）无法识别的结构化信息，从而产生独特的“视觉 Alpha”。

3.3 迁移学习与本地化重训：跨市场的挑战与机遇

Jiang et al. (2023) 的研究特别指出，他们基于美股训练的模型在跨市场（比如亚洲的小国）中仍然具备不俗的表现，但是在中国和印度市场“水土不服”。笔者基于这一结论，进行中国市场的复现。

本次复现实验最显著的发现是：直接迁移美股模型至中国市场效果不佳（H-L 为负），而本地重训练模型效果惊人（累计 H-L 超 20%）。

表 1 清晰地展示了这一点。

表 1　复现实验：跨市场迁移与本地训练的效果对比

实验设置	总体准确率	上涨准确率	下跌准确率	平均 H–L (%)	累计 H–L
美股模型在美股测试集	0.523	0.516	0.532	1.56	3.55
美股模型迁移至中国（失灵）	0.491	0.673	0.322	-0.46	-3.72
中国本地 CNN 模型（显著）	0.526	0.579	0.477	2.49	20.22

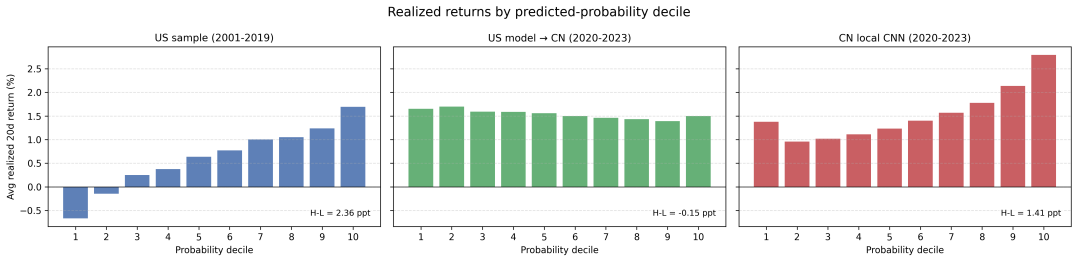
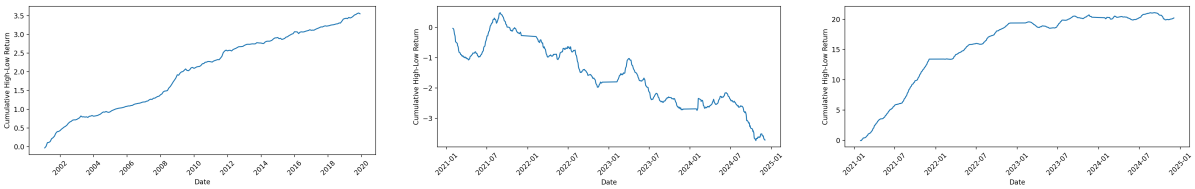


图 5　不同模型下的十等分组合收益特征

图 6 展示了三个实验设置下的累计收益表现，进一步印证了“视觉 Alpha”的高度本地化特征。



(a) 美股样本 (2001-2019) **(b) 迁移模型 (2020-2023)** **(c) 本地模型 (2020-2023)**

图 6　跨市场累计收益对比：美股基准 vs 迁移失效 vs 本地重训

笔者尝试对此做一阐释：

1. 两个市场在交易主体上存在区别：美股是机构主导，走势相对平滑，动量效应强；A 股散户比例极高，容易出现羊群效应，导致价格形态（如急涨急跌）与美股不同。

2. 中国市场的技术分析文化更为根深蒂固，投资者对 K 线图的解读习惯与美股有显著差异。这种文化差异导致了图像特征的语义映射不同。特别是在政策面的分析上，其“量价关系”与“政策预期”在中国市场中扮演着更为重要的角色。

3. 交易制度的差异也不可忽视。中国市场的涨跌停限制、T+1 交易制度等，都使得价格形态的演变与美股有本质区别。这些制度性因素导致了图像特征在不同市场中的表现差异。

综上所述，图像识别并非简单的“看图”，而是对市场微观结构与投资者行为模式的深度编码。在中国市场进行本地化训练的巨大成功证明，只有将深度学习技术与具体的金融市场环境相结合，才能真正解开资产价格趋势的密码。

参考文献

[1] Gu S, Kelly B, Xiu D. Empirical asset pricing via machine learning[J]. The Review of Financial Studies, 2020, 33(5): 2223-2273.

[2] Jiang J, Kelly B, Xiu D. (Re-)Imag(in)ing Price Trends[J]. The Journal of Finance, 2023, 78(6): 3193-3249.

[3] Lopez-Lira A, Tang Y. Can chatgpt forecast stock price movements? return predictability and large language models[J]. arXiv preprint arXiv:2304.07619, 2023.

[4] Feng F, He X, Wang X, et al. Temporal relational ranking for stock prediction[J]. ACM Transactions on Information Systems (TOIS), 2019, 37(2): 1-30.

[5] Xu Z, Liu Y, Wang Y, et al. Modeling Interactions Between Stocks Using LLM-Enhanced Graphs for Volume Prediction[J]. FinNLP, 2025.

[6] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[C]//European conference on computer vision. Springer, Cham, 2014: 818-833.

[7] Yu F, Koltun V. Multi-scale context aggregation by dilated convolutions[J]. arXiv preprint arXiv:1511.07122, 2015.

附录：大语言模型（LLM）使用说明

声明：在撰写本研读报告的过程中，本人使用了 Google Gemini 模型辅助进行了文献检索、思路整理及 LaTeX 格式调整。具体使用情况如下：

1. **问题提出与文献检索：**
    - **提问内容：**“请推荐几篇与机器学习驱动的资产定价相关的、最新的前沿文献。”以及“请推荐两篇计算机视觉经典文献，用于佐证 CNN 的层级化特征提取和膨胀卷积的作用。”
    - **LLM 回答情况：** LLM 提供了 Gu et al. (2020) 和 Jiang et al. (2023) 等核心文献；并补充了 Zeiler and Fergus (2014) 与 Yu and Koltun (2015) 以为本文的计算机视觉类比提供理论支撑。
2. **思路框架构建：**
    - **提问内容：**“如何基于图像识别资产定价论文撰写一篇包含研究展望的研读报告?”
    - **LLM 回答情况：** LLM 建议在研究展望部分讨论“多模态融合”和“图神经网络结合”的方向，并协助梳理了卷积层与金融语义的映射关系。
3. **格式调整与排版：**
    - **提问内容：**“根据课程要求（小四字号、参考文献格式等）调整 LaTeX 代码。”
    - **LLM 回答情况：** LLM 协助修改了文档类设置（zihao=-4），规范了参考文献的引用格式，并检查了文档结构。

致谢：

本文是笔者本科生涯中第一篇金融学方向的研读报告，能够顺利完成离不开多方的支持与帮助。衷心感谢 ECON30122h.01 公司金融 [H] 课程的任课教师杨青老师及助教赵宇轩博士生，感谢他们在课程中系统讲解了资产定价的核心理论与前沿方法。特别感谢 Dacheng Xiu 教授慷慨开源的美国股市图像数据，这为我迈出实证检验的第一步提供了莫大帮助。

笔者八月在日本旅游时，以“迷失表参道”这一歌名戏称自己迷失在了繁华而拥挤的表参道，这个学期接触资产定价，发现自己更是“迷失因子道”。陆铭教授告诫我们，经济学研究不能“为了显著性”去做，同样的，资产定价研究也不能“为了因子”去做。

谨以本文为一个开端，在技术压过直觉的世界里，笔者希望可以不断扩展自己的技术视野与经济学直觉，或许是在图神经网络、或许是在大语言模型、或许是在强化学习，去探索资产定价的更多可能性。